PUCPR

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ

DATA ANALYTICS / PROJETO BASEADO EM PROBLEMAS

RA1

Ingestão e preparação dos dados

Modelo de documentação da entrega

Projeto Análise do mercado de jogos na Steam

Curso e turma Sistemas de Informação • Turma 6° GCL1 • 2026/2

Professor ou professora Marina de Lara

Equipe Gustavo Delinski Tavares e Eduardo Jabur

Repositório: https://github.com/Gustavo-Delinski/Data-analytics

Entrega Curitiba • 21/10/2026

Este documento acompanha a implementação no repositório. Registre o caminho dos arquivos, notebooks ou células que comprovam cada etapa. O resultado do RA1 será a base para os próximos RAs.

RA1 / 01

Problema e perguntas analíticas

Defina o contexto do projeto e as perguntas que orientarão a seleção e a preparação dos dados.

Contexto e problema

A Steam é a maior loja de jogos para PC e recebe dezenas de milhares de lançamentos por ano (quase 25 mil só em 2025, segundo a base usada). Com tanta concorrência, desenvolvedores e pequenos estúdios precisam decidir que tipo de jogo produzir tendo pouca informação sobre o que mantém os jogadores e sobre quais gêneros estão crescendo.

O problema investigado é entender, com dados públicos da loja, quais gêneros prendem mais os jogadores, quais gêneros mais cresceram em lançamentos e como jogos gratuitos e pagos se comparam em popularidade. Os principais afetados são desenvolvedores e publicadoras, que podem usar essas informações para escolher o gênero e o modelo de negócio de um novo jogo.

Objetivo e recorte

Objetivo: preparar uma base confiável de jogos da Steam que permita responder às três perguntas analíticas nas próximas etapas.

Unidade de análise: cada jogo da loja Steam. Itens que são apenas software ou vídeo ficam fora.

Período: a P2 usa lançamentos de 2020 a 2025, porque 2025 é o último ano completo na base (a coleta vai até cerca de março de 2026). A P1 e a P3 usam todos os jogos que têm o dado necessário, sem recorte de ano.

Limites: a base não tem dados de jogadores voltando ao jogo ao longo do tempo, então o tempo mediano de jogo é usado como aproximação de retenção. O número de donos é uma faixa estimada pelo SteamSpy, não um valor exato.

Perguntas analíticas

ID	Pergunta a investigar	Dados necessários
P1	Quais gêneros apresentam maior tempo mediano de jogo por jogador?	Genres e Median playtime forever • jogos com tempo de jogo informado
P2	Quais gêneros tiveram maior crescimento no número de lançamentos entre 2020 e 2025?	Genres e Release date (ano) • lançamentos de 2020 a 2025
P3	Entre os 100 jogos com mais donos estimados, como gratuitos e pagos se comparam em pico de jogadores simultâneos e proporção de avaliações positivas?	Estimated owners, Price, Peak CCU, Positive e Negative • 100 jogos com mais donos

Viabilidade inicial

A base tem as variáveis necessárias para as três perguntas: gêneros e tempo mediano de jogo (P1), gêneros e data de lançamento (P2), e donos estimados, preço, pico de jogadores e avaliações (P3).

Lacunas: só cerca de 21% dos registros têm tempo de jogo informado (os demais vêm com 0), o que é suficiente para a P1, mas a deixa concentrada em jogos com mais jogadores. Na P2, cada ano de 2020 a 2025 tem entre 8.804 e 24.973 lançamentos, volume suficiente para comparar gêneros. Na P3, como os donos vêm

em faixas, o corte dos 100 jogos com mais donos cai dentro da faixa de 5 a 10 milhões (95 itens estão acima de 10 milhões na base original), então será necessário um critério de desempate, como o pico de jogadores.

RA1 / 02

Fontes de dados e ingestão

Documente a origem dos dados e como eles são carregados no ambiente do projeto. Duplique a ficha para cada fonte.

Ficha da fonte

Identificação F1 • Steam Games Dataset (arquivo games.csv)

Origem e acesso FronkonGames, a partir da API da Steam e do SteamSpy • https://www.kaggle.com/datasets/fronkongames/steam-games-dataset • acesso em 19/10/2026

Formato e volume CSV (também disponível em JSON, não utilizado) • 125.855 registros • 40 atributos

Cobertura Itens da loja Steam lançados entre 30/06/1997 e 01/12/2026 (datas futuras são jogos anunciados) • coleta até cerca de março de 2026 • loja global, preços em dólar (USD)

Condições de uso Dados públicos, sem informações pessoais • licença aberta informada pelo autor na página do conjunto • uso acadêmico

Relação com o problema

É a única fonte do RA1 e apoia as três perguntas: Genres e Median playtime forever (P1), Genres e Release date (P2), e Estimated owners, Price, Peak CCU, Positive e Negative (P3). Foi escolhida por reunir em um único arquivo os dados da loja (preço, gêneros, data) e as estimativas de uso do SteamSpy (donos e tempo de jogo), que a API oficial da Steam não fornece.

Procedimento de ingestão

Etapa	Procedimento ou parâmetro	Evidência no repositório
1	O games.csv foi baixado manualmente da página do Kaggle (botão Download), extraído do arquivo compactado e enviado para a pasta /content do Google Colab. O download pelo próprio notebook (kagglehub) não funcionou no ambiente de um dos integrantes, por isso o envio manual.	Notebook, seção 2 • texto da ingestão e variável caminho_csv
2	Leitura com pd.read_csv(caminho_csv) usando os padrões (separador vírgula, UTF-8, cabeçalho na 1ª linha). Como o cabeçalho tinha 39 nomes para 40 valores, o arquivo é relido com header=None, skiprows=1 e names=colunas, trocando "DiscountDLC count" por "Discount" e "DLC count".	Notebook, seção 2 • células da primeira leitura e da correção do cabeçalho
3	Conferência do formato com df.shape: (125855, 39) na primeira leitura e (125855, 40) após a correção. df.info() confirma tipos coerentes (Price float64, Discount e DLC count int64).	Notebook, seções 2 e 3 • df.shape e df.info()

Resultado da ingestão

Foram carregados 125.855 registros e 40 colunas no DataFrame df. Os dados brutos ficam em /content/games.csv e o arquivo original não é alterado: a correção do cabeçalho é feita apenas na leitura.

Etapa manual: o games.csv é baixado do Kaggle e enviado ao Colab à mão. Como o Colab apaga a pasta /content quando a sessão termina, o envio precisa ser repetido a cada nova sessão.

RA1 / 03

Compreensão e qualidade

Descreva o que cada registro representa e apresente evidências das verificações de qualidade relevantes para os dados.

Unidade de observação Uma linha representa um item da loja Steam (na maioria jogos, mas também softwares e vídeos), identificado pelo AppID.

Identificação dos registros AppID é chave única (0 repetidos) • nomes se repetem em 1.210 casos, em geral jogos diferentes • Name + Developers + Release date identifica o mesmo jogo cadastrado mais de uma vez

Dicionário inicial dos dados

Atributo	Significado	Tipo e formato	Unidade ou domínio
AppID	Identificador do item na Steam	int64	Inteiro único
Name	Nome do item	Texto	Texto livre • 1 vazio
Release date	Data de lançamento	Texto "Mon DD, YYYY"	30/06/1997 a 01/12/2026
Estimated owners	Faixa de donos estimada pelo SteamSpy	Texto em faixa ("0 - 20000")	14 faixas, de "0 - 0" a "100000000 - 200000000"
Peak CCU	Pico de jogadores simultâneos no dia anterior à coleta	int64	Jogadores
Price	Preço na loja	float64	Dólar (USD) • 0 = gratuito
Positive	Avaliações positivas	int64	Quantidade
Negative	Avaliações negativas	int64	Quantidade
Median playtime forever	Tempo mediano de jogo por jogador	int64	Minutos • 0 = sem dado
Genres	Gêneros marcados pelo desenvolvedor	Texto separado por vírgula	33 valores distintos (jogo, software e rótulos)
Developers	Desenvolvedora(s)	Texto	Texto livre • 8.449 vazios
Publishers	Publicadora(s)	Texto	Texto livre • 8.922 vazios

Diagnóstico de qualidade

ID	Verificação e regra	Resultado observado	Evidência

ID	Verificação e regra	Resultado observado	Evidência
Q1	Cabeçalho • nº de nomes de coluna x nº de valores por linha	39 nomes para 40 valores: Discount e DLC count vinham unidas em "DiscountDLC count", deslocando os valores uma coluna para a esquerda	Seção 2 • df.columns.tolist()
Q2	Ausentes • isna().sum() nas colunas usadas	Genres: 8.423 (6,7%) • Name: 1 • Developers: 8.449 • Publishers: 8.922. Colunas com muitos vazios (Website, Metacritic url, Movies etc.) não são usadas	Seção 3 • df.isna().sum()
Q3	Zeros como falta de dado • Median playtime forever = 0 e Estimated owners = "0 - 0"	99.682 tempos zerados (79,2%) e 24.579 faixas "0 - 0" (19,5%). O SteamSpy não estima itens com poucos jogadores	Seção 3 • proporção de zeros
Q4	Valores válidos • Price = 0	21,2% com preço 0. São jogos gratuitos: sem problema	Seção 3 • proporção de zeros
Q5	Tipo • Estimated owners	Texto em faixas (ex: "0 - 20000"), não permite ordenar nem comparar	Seção 3 • value_counts()
Q6	Formato e domínio • Release date com formato %b %d, %Y	Texto. Conversão com 0 falhas, de 1997 a 2026. 2026 incompleto (3.316 itens, coleta até março) e 3 datas futuras (jun, set e dez/2026)	Seção 3 • pd.to_datetime e contagem por ano e mês
Q7	Categorias • Genres classificado em gênero de jogo, de software ou rótulo	1.491 itens só com gêneros de software/vídeo • 410 misturam jogo e software • 220 só com rótulos (Free To Play, Early Access, Violent etc.)	Seção 3 • generos_software e rotulos_nao_genero
Q8	Outliers • maiores valores de Median playtime forever	Valores implausíveis, como Avem33 com 3.429.544 minutos (cerca de 6,5 anos ininterruptos)	Seção 3 • nlargest(5)
Q9	Duplicados • AppID; Name; Name + Developers + Release date	AppID: 0 • Name: 1.210 (em geral jogos diferentes) • Name + Developers + Release date: 111 (mesmo jogo cadastrado mais de uma vez)	Seção 3 • duplicated()

Impacto dos problemas identificados

Prioridade alta: o cabeçalho deslocado (Q1) invalidava todas as colunas e precisava ser corrigido antes de qualquer outra verificação. Os zeros que indicam falta de dado (Q3) também são críticos: tratados como valor real, puxariam para baixo o tempo mediano de jogo na P1 e colocariam cerca de 24 mil itens como se tivessem zero donos na P3.

Prioridade média: os itens que não são jogos (Q7) e os duplicados (Q9) distorcem as contagens de lançamentos por gênero na P2 e o ranking de donos na P3. Os tipos incorretos (Q5 e Q6) impedem ordenar por donos e filtrar por ano.

Baixo impacto: os outliers de tempo de jogo (Q8) são poucos e a P1 usa mediana. Price = 0 (Q4) é um valor legítimo. O único nome ausente (Q2) não afeta as análises, e os vazios de Genres (Q2) apenas reduzem a amostra da P1 e da P2.

RA1 / 04

Limpeza e preparação

Relacione cada intervenção ao diagnóstico. Justifique tanto os tratamentos realizados quanto as decisões de manter os dados.

Registro das decisões

Decisão e diagnóstico D1 • relacionado a Q3 e Q5 • donos estimados em número

Problema e abrangência

Coluna Estimated owners, texto em faixas, nos 125.855 registros. Destes, 24.579 têm a faixa "0 - 0".

Tratamento e justificativa

Criamos owners_min, owners_max e owners_medio (ponto médio da faixa), mantendo a coluna original. O ponto médio é uma aproximação, mas permite ordenar e comparar jogos na P3.

Os registros "0 - 0" viraram vazio nas colunas novas, porque representam falta de estimativa, não zero donos. Efeito: esses itens ficam fora do ranking de donos.

Implementação Notebook, seção 4 • célula com str.split(" - ") e owners_medio

Validação após o tratamento

O tipo passou de object para float64 e owners_medio ficou com 24.579 vazios, o mesmo número de registros "0 - 0". A amostra confirma o cálculo (ex: "20000 - 50000" gerou 35.000).

Decisão e diagnóstico D2 • relacionado a Q3 • tempo de jogo zerado

Problema e abrangência

Coluna Median playtime forever: 99.682 registros (79,2%) com valor 0.

Tratamento e justificativa

Os zeros foram convertidos em vazio com mask(). Remover esses registros apagaria 79% da base e prejudicaria a P2, que não depende de tempo de jogo. Como vazio, eles ficam automaticamente fora do cálculo da mediana na P1. Efeito: a P1 passa a representar só os jogos com tempo informado.

Implementação Notebook, seção 4 • célula com df_limpo[col].mask(df_limpo[col] == 0)

Validação após o tratamento

Zeros depois: 0. Vazios depois: 99.682, igual ao número de zeros antes.

Decisão e diagnóstico D3 • relacionado a Q6 • data de lançamento

Problema e abrangência

Coluna Release date, em texto no formato "Mon DD, YYYY", em todos os registros.

Tratamento e justificativa

Convertida para data com pd.to_datetime e formato fixo %b %d, %Y. O formato fixo evita que alguma data seja interpretada de forma errada e permite extrair o ano para a P2.

Implementação Notebook, seção 4 • célula com pd.to_datetime(..., format="%b %d, %Y")

Validação após o tratamento

O tipo passou de object para datetime64. Na exploração (seção 3), a mesma conversão gerou 0 falhas.

Decisão e diagnóstico D4 • relacionado a Q7 • itens que não são jogos

Problema e abrangência

1.491 itens com apenas gêneros de software ou vídeo (Utilities, Video Production, Movie etc.) e 410 itens que misturam gêneros de jogo e de software.

Tratamento e justificativa

Removidos os 1.491 itens só de software/vídeo, pois não são jogos e distorceriam as contagens por gênero.

Os 410 mistos foram mantidos: são cerca de 0,3% da base e separar manualmente quais são jogos não seria viável. Efeito: alguns softwares marcados com gênero de jogo continuam na base.

Implementação Notebook, seção 4 • célula com df_limpo.drop(index=so_software...)

Validação após o tratamento

Os registros passaram de 125.855 para 124.364, exatamente 1.491 a menos.

Decisão e diagnóstico D5 • relacionado a Q2 • registro sem nome

Problema e abrangência

1 registro com Name vazio.

Tratamento e justificativa

Removido, pois não é possível identificar o jogo. O impacto na base é desprezível.

Implementação Notebook, seção 4 • célula com dropna(subset=["Name"])

Validação após o tratamento

Itens sem nome: 1 antes e 0 depois.

Decisão e diagnóstico D6 • relacionado a Q9 • registros duplicados

Problema e abrangência

111 registros repetidos pela chave Name + Developers + Release date.

Tratamento e justificativa

Antes de remover, ordenamos por owners_medio e Positive em ordem decrescente e usamos drop_duplicates com keep="first". Assim, de cada grupo repetido fica a cópia com dados reais de donos e avaliações, e não a cópia vazia.

Nomes repetidos com desenvolvedor ou data diferentes foram mantidos, pois são jogos distintos.

Implementação Notebook, seção 4 • célula com sort_values e drop_duplicates(subset=chave)

Validação após o tratamento

Duplicados pela chave: 111 antes e 0 depois, ficando 124.252 registros. Exemplo: Assassin's Creed 2 manteve a versão com 2 a 5 milhões de donos (AppID 33230).

Decisão e diagnóstico D7 • relacionado a Q7 • padronização dos gêneros e colunas de apoio

Problema e abrangência

Genres mistura gêneros de jogo com gêneros de software e rótulos que não são gênero (Free To Play, Early Access, Violent, Gore, Nudity, Sexual Content). Também faltavam colunas para o modelo de negócio e para o ano.

Tratamento e justificativa

Criamos generos_jogo, só com gêneros de jogo, mantendo a coluna Genres original; gratuito (Price = 0), usada na P3; e ano_lancamento, usada na P2.

Por fim, selecionamos as 18 colunas usadas nas perguntas e no RA2. Descrições, imagens, links e e-mails foram descartados por não serem usados.

Implementação Notebook, seção 5 • células com generos_jogo e colunas_finais

Validação após o tratamento

Na amostra, "Casual,Indie,RPG,Strategy,Early Access" virou "Casual,Indie,RPG,Strategy". 8.642 jogos ficaram sem gênero de jogo (Genres vazio ou só rótulos). df_final.info() confirma 18 colunas.

Decisão e diagnóstico D8 • relacionado a Q2, Q4, Q6 e Q8 • valores mantidos

Problema e abrangência

Preços iguais a 0 (21,2%), datas futuras e ano de 2026 incompleto, tempos de jogo extremos (ex: Avem33) e 8.423 registros sem Genres.

Tratamento e justificativa

Mantidos sem alteração. Preço 0 é um valor legítimo (jogos gratuitos). Datas futuras e 2026 não entram no recorte de 2020 a 2025 da P2, então não precisam ser removidas.

Os tempos extremos são poucos e a P1 usa mediana, pouco afetada por eles; excluí-los exigiria um limite arbitrário. Itens sem gênero continuam úteis para a P3, que não depende de gênero.

Implementação Não se aplica (decisão de manter) • justificativa no notebook, seção 4

Validação após o tratamento

Verificado na exploração (seção 3). No conjunto final, os preços 0 aparecem como gratuito = True e Release date continua cobrindo de 1997 a 2026; o recorte de ano será aplicado nas análises da P2.

Resumo das intervenções

Decisão	Ação executada	Impacto nos dados	Evidência
D1	Faixa de donos convertida em owners_min, owners_max e owners_medio; "0 - 0" virou vazio	+3 colunas • 24.579 vazios	Seção 4

Decisão	Ação executada	Impacto nos dados	Evidência
D2	Zeros de Median playtime forever viraram vazio	99.682 valores • nenhum registro removido	Seção 4
D3	Release date convertida para data	1 coluna, todos os registros	Seção 4
D4	Remoção dos itens só de software/vídeo	-1.491 registros	Seção 4
D5	Remoção do registro sem nome	-1 registro	Seção 4
D6	Remoção de duplicados, mantendo a cópia com mais dados	-111 registros	Seção 4
D7	Criação de generos_jogo, gratuito e ano_lancamento; seleção de colunas	+3 colunas • 40 para 18 colunas no final	Seção 5
D8	Manutenção de preços 0, datas futuras, tempos extremos e Genres vazios	Nenhum registro alterado	Seções 3 e 4

RA1 / 05

Conjunto de dados resultante

Identifique a saída do RA1 e demonstre sua consistência para uso nas próximas etapas.

Arquivo ou conjunto final steam_games_limpo.csv • gerado pela última célula da seção 5 do notebook (DataFrame df_final) • CSV

Unidade de observação final Uma linha representa um jogo da loja Steam, sem itens só de software/vídeo e sem duplicados, identificado pelo AppID.

Dicionário atualizado Atributos originais na seção 03 deste documento • colunas novas em D1 (owners_min, owners_max, owners_medio) e D7 (generos_jogo, gratuito, ano_lancamento) • tipos finais em df_final.info(), seção 5 do notebook

Comparação antes e depois

Medida	Após ingestão	Após preparação	Explicação da diferença
Registros	125.855	124.252	-1.491 itens só de software (D4), -1 sem nome (D5) e -111 duplicados (D6)
Atributos	40	18	12 originais mantidos e 6 criados (D1 e D7); os demais foram descartados por não serem usados
Duplicados (Name + Developers + Release date)	111	0	D6
AppID duplicado	0	0	Sem alteração: a chave já era única
Itens só de software/vídeo	1.491	0	D4
Zeros em Median playtime forever	99.682 (79,2% de 125.855)	0	D2: viraram vazio; 25.836 jogos com tempo informado
Tipo de Release date e Estimated owners	Texto	datetime64 e float64 (owners_medio)	D3 e D1

Verificações finais

Tipos: df_final.info() mostra Release date como datetime64, owners_min, owners_max e owners_medio como float64, gratuito como bool e ano_lancamento como int32.

Duplicidade e integridade: 0 AppID repetido e 0 duplicados pela chave Name + Developers + Release date (célula de validação da seção 5).

Ausências: AppID, Name, Release date, Price e Estimated owners estão completos (124.252 valores). Os vazios restantes são conhecidos e intencionais: owners_medio (24.369, sem estimativa do SteamSpy), Median playtime forever (98.416, tempo não informado) e generos_jogo (8.642, sem gênero de jogo).

Domínios: Median playtime forever não tem mais zeros e owners_medio contém apenas pontos médios de faixas válidas.

Limitações e pendências

O número de donos é uma faixa estimada pelo SteamSpy. O ponto médio é uma aproximação e gera empates no ranking da P3.

Só 25.836 jogos têm tempo de jogo informado, então a P1 representa principalmente jogos com mais jogadores. Além disso, o tempo de jogo é uma aproximação de retenção, não uma medida direta.

A separação entre jogo e software depende dos gêneros marcados pelo desenvolvedor, que nem sempre são confiáveis. Os 410 itens mistos continuam na base.

O ano de 2026 está incompleto e as datas futuras foram mantidas. Análises por ano devem usar o recorte de 2020 a 2025.

Os tempos de jogo extremos foram mantidos, então as análises de tempo de jogo devem usar mediana.

A base do Kaggle é atualizada periodicamente. Um novo download pode trazer números diferentes dos registrados aqui.

RA1 / 06

Organização e reprodutibilidade

Explique como outra pessoa pode obter os dados e executar o fluxo completo do RA1.

Repositório e versão: https://github.com/Gustavo-Delinski/Data-analytics 1.0

Ambiente Python 3 no Google Colab • pandas (versão padrão do Colab) • sem arquivo de dependências, pois o Colab já inclui o pandas

Localização dos artefatos

Artefato	Caminho ou forma de obtenção
Dados brutos	games.csv do Steam Games Dataset: baixar em https://www.kaggle.com/datasets/fronkongames/steam-games-dataset (botão Download), extrair do arquivo compactado e enviar para /content no Colab
Código de ingestão e preparação	Notebook do projeto (.ipynb), seções 2 a 5
Dados preparados	steam_games_limpo.csv, gerado e baixado pela última célula da seção 5
Documentação e dependências	Este documento e as células "Resposta do grupo" do notebook • sem arquivo de dependências

Passos para reprodução

Ordem	Instrução executável	Resultado esperado
1	Abrir o notebook no Google Colab	import pandas executa sem erro
2	Baixar o games.csv no Kaggle e enviá-lo pelo painel Arquivos do Colab para /content	games.csv aparece em /content/games.csv
3	Executar as células das seções 2 a 5, na ordem	Primeira leitura mostra (125855, 39) e, após a correção do cabeçalho, (125855, 40)
4	Conferir a validação final e localizar a saída	124.252 registros, 18 colunas e 0 duplicados • steam_games_limpo.csv baixado

Verificação da reprodução

Execução completa em 20/10/2026, no Google Colab, por Gustavo Delinski Tavares, com o games.csv enviado manualmente para /content. O fluxo reproduziu os números registrados neste documento: 125.855 registros e 40 colunas após a ingestão, e 124.252 registros e 18 colunas após a preparação, sem duplicados.

RA1 / 07

Referências e anexos

Reúna as fontes utilizadas e os materiais complementares que ajudam a verificar a entrega.

Referências

FRONKONGAMES. Steam Games Dataset. Kaggle, 2026. Disponível em: https://www.kaggle.com/datasets/fronkongames/steam-games-dataset. Acesso em: 19/10/2026

Anexos opcionais

Identificação	Conteúdo	Localização
Anexo A	Notebook do projeto (.ipynb) com todas as células executadas: código, saídas e justificativas	Repositório do projeto
Anexo B	steam_games_limpo.csv, conjunto de dados preparado	Repositório do projeto (gerado pela seção 5 do notebook)

Conferência da entrega

☒ Problema, recorte e perguntas analíticas estão definidos.

☒ Fontes e procedimentos de ingestão estão documentados.

☒ A qualidade foi avaliada com evidências verificáveis.

☒ As decisões de limpeza estão justificadas e validadas.

☒ O conjunto de dados preparado está identificado.

☒ O repositório contém instruções suficientes para reprodução.

☒ Os campos-modelo foram preenchidos e os exemplos revisados.